

推荐系统数据集

店家名称补全与描述类别分类

实验报告

数据范围：restaurants.csv

rating.csv

1. 项目背景与问题定义

本项目的主要目的是推荐系统数据集中的店家信息完善。数据表 `restaurants.csv` 以 `restId` 为商家标识，但部分记录缺失 `name`，且没有能直接反映商家业态的类别字段；`ratings.csv` 则包含用户评论。初步查看发现，评论中较少直接出现完整店名，更多描述消费内容、菜品、服务和消费场景，例如火锅、牛肉面、住宿、学车或买菜。因此，评论文本会作为商家类别识别的主要证据。

本实验要解决的问题是：在不覆盖原始 `restaurants.csv` 的前提下，如何利用 `ratings.csv` 中的评论补全部分缺失店名，并为所有店家生成一个可供后续统计与推荐特征使用的粗粒度类别。具体完成以下两项指定任务：

- 以缺少 `name` 的 `restId` 为对象，基于 `ratings.csv` 的评论提取并筛选店名候选，完成可识别名称的补全。
- 以补名后的店家表和全部评论为依据，为每个 `restId` 新增一列“描述类别”；类别采用餐饮、超市、酒店、酒吧、电商等大类，无法可靠判断时标记为“不确定”。

2. 数据概览

实验使用店家基础表 `restaurants.csv`、评分评论表 `ratings.csv`，以及处理过程中生成的候选名称表和最终结果表。两张原始表通过 `restId` 关联：前者提供待补全的店家记录，后者提供文本证据。`ratings.csv` 规模超过四百万行，因此采用 CSV 分片和流式读取完成统计，避免 Excel 行数上限与一次性加载的内存问题。

数据对象	规模/说明
<code>restaurants.csv</code>	243,247 条店家记录；初始缺失名称 34,115 个 <code>restId</code>
<code>ratings.csv</code>	4,422,473 条评分记录；其中非空评论 4,107,409 条
缺名店家评论子集	744,124 条非空评论，用于名称候选提取
<code>restaurants_final.csv</code>	243,247 条商家记录；字段为 <code>restId</code> 、 <code>name</code> 、描述类别

3. 任务一：店家名称补全

3.1 总体思路

先利用 `restaurants.csv` 中已有名称区分已命名和缺失名 `restId`；仅对缺名店家的评论进行候选名称提取。候选以 `restId` 为单位累计票数，同一候选在多条评论中被重复提及时，其可信度随票数上升。随后将低票数、泛称、句子片段与明显无效表达从自动补名范围中分离。

3.2 候选提取与筛选流程

- 从缺名店家的非空评论中逐条提取可能指向商家的短语，并按 `restId`、候选名称聚合票数。
- 通过规则清洗剔除“这家”“上面”“一层是超市”等指代词、位置词和句子片段；淘宝、京东等平台词保留为线上商家名称候选。
- 票数不少于 3 的候选直接进入高可信候选集；恰好 2 票的候选交由大语言模型进行语义筛选，标签包括具体店名、平台/线上商家名、泛称或句子片段与不确定。
- 合并被接受的候选后，每个 `restId` 选择最高票名称；最高票并列时按候选排序取第一项，并保留处理规则。

3.3 名称补全结果

环节	结果
候选聚合	共 139,408 条候选记录，覆盖 17,779 个缺名的 <code>restId</code>
高票候选	票数不少于 3 的候选 760 条
两票候选	恰好 2 票的候选 2,295 条
大语言模型筛选	两票候选中接受 755 条（具体店名或平台/线上商家名）
最终补名	成功补全 1,267 个 <code>restId</code> ；最高票并列的 57 个 <code>id</code> 按既定规则取首项

补名结果写入 `restaurants_name_draft_selected_candidates.csv`，共补全 1,267 个 `restId` 的名称。原始 `restaurants.csv` 未被覆盖，保证了数据处理过程可回溯。

4. 任务二：店家描述类别分类

4.1 类别体系与规则

分类采用可解释的关键词弱监督分类，而非为每一条评论人工标注。类别体系共 14 类：电商平台/线上零售、超市/便利店、市场/花鸟市场、景点/公园/公共场所、教育培训/驾校、餐饮-火锅烧烤、餐饮-茶饮咖啡甜品、酒吧/夜生活、酒店/住宿、购物零售、生活服务、休闲娱乐、餐饮-正餐和不确定。其中，餐饮类关键词使用基于本数据集评论样本人工维护的精简词典，覆盖常见菜品、主食、菜系和餐饮业态词，例如烤鸭、牛肉面、酸菜鱼、泡馍、农家菜和东南亚菜。该做法优先保证关键词的针对性与运行效率。

计算时，店名命中类别关键词记为较高权重（5 分）；评论中每出现一次该类别的关键词，最多为该类别贡献 1 分，以避免单条长评论因重复措辞被过度放大。每个 `restId` 选择总分最高的类别；名称与评论均无命中时归为“不确定”。最终输出仅保留 `restId`、`name`、描述类别三列。

4.2 大语言模型辅助复核

在关键词规则分类后，仍标记为“不确定”的商家才进入大语言模型辅助复核流程，而不是对全部评论逐条调用模型。处理单位为 `restId`：每家最多选取 2 条信息量较高的评论，每条最多保留 120 个字符，10 家商家合并为一批请求。调用 DeepSeek 大语言模型时，模型只能从既定的 14 个类别中选择，并以 JSON 返回描述类别和置信度。模型输出逐批保存为 `category_llm_screened.csv`，该文件记录每个待复核 `restId` 的名称、入模评论、模型类别与置信度；共完成 20,035 家商家的复核。仅将高置信度且非“不确定”的 12,628 家商家写入 `restaurants_final.csv`，原始规则分类结果始终保留。该设计将大语言模型定位为基础筛选后对规则难以覆盖样本的补充，而非替代全部规则分类。

从覆盖范围看，名称补全模型仅复核 2,295 条恰好两票的候选记录，占 139,408 条全部名称候选记录的 1.65%，涉及 1,752 个 `restId`（占有候选名称商家的 9.85%）；类别分类模型复核 20,035 家规则仍无法确定类别的商家，占全部 243,247 家商家的 8.24%。因此，两个模型均在规则初筛后针对小范围难判样本使用，而非直接处理全量评论或全量商家。

4.3 分类结果

全部 243,247 个店家均已写入“描述类别”。这里的“不确定”是一个保留类别，表示名称和评论中均未获得足够的类别证据，而不是将该店家强行归入某个业态。数量最多的类别为“餐饮-正餐”，其次为“不确定”和“餐饮-茶饮咖啡甜品”，具体分布见下表。

描述类别	店家数量	占比
餐饮-正餐	130,504	53.65%
餐饮-茶饮咖啡甜品	32,864	13.51%
餐饮-火锅烧烤	24,687	10.15%
购物零售	10,067	4.14%
酒店/住宿	9,192	3.78%
不确定	8,534	3.51%
生活服务	6,180	2.54%
景点/公园/公共场所	5,460	2.24%
休闲娱乐	5,151	2.12%
超市/便利店	4,377	1.80%
酒吧/夜生活	3,692	1.52%
教育培训/驾校	1,472	0.61%
电商平台/线上零售	683	0.28%
市场/花鸟市场	384	0.16%

各描述类别的店家数量与占比

5. 处理过程与结果文件

本实验采用 Notebook 分步记录数据处理过程，最终结果与中间证据文件相互独立，便于复核和继续优化。

其中，llm_two_vote_candidate_screening.ipynb 和 llm_category_classification.ipynb 均需要用户自行提供可用的 DeepSeek API Key；密钥仅在当前 Notebook 会话中以隐藏输入方式使用，不写入代码或结果文件。前者的模型筛选结果已导出为 name_two_vote_llm_screened.csv，后者的模型分类结果已导出为 category_llm_screened.csv。

文件	用途
restaurants_name_completion.ipynb	名称候选提取、规则清洗、票数筛选与补名草稿生成

llm_two_vote_candidate_screening.ipynb	对两票候选进行大语言模型语义筛选
restaurants_category_classification.ipynb	基于名称与评论生成描述类别
restaurants_category_draft.csv	基于关键词规则生成的类别初稿；用于识别待大语言模型复核的“不确定”商家
llm_category_classification.ipynb	对规则无法判定的商家按 restId 聚合评论，并进行大语言模型辅助类别复核
category_llm_tasks.csv	关键词规则初筛后，为“不确定”商家按 restId 聚合评论生成的大语言模型输入任务表
category_llm_screened.csv	DeepSeek 大语言模型生成的分类结果文件，包含 restId、名称、入模评论、描述类别和置信度
restaurants_final.csv	将高置信度且非“不确定”的大语言模型结果合并后的最终商家表

6. 局限性与后续优化

- 名称补全只覆盖评论中存在足够明确名称证据的店家，未被补名并不等于该店不存在，只表示现有评论不足以可靠识别。
- 平台词可以表示线上商家，也可能仅指交易渠道；在后续分析中可增加“平台/渠道”与“具体店铺”双层标签，减少语义混淆。
- 关键词分类具有可解释、成本低的优点，但对同义词、隐含语义和跨类别评论的识别有限。大语言模型能够补充规则难以覆盖的样本，但其输出仍可能存在类别边界差异或格式异常，因此本实验仅接受高置信度且非“不确定”的模型结果；后续可对不确定样本和低频类别进行抽样标注，以评估并进一步优化分类质量。

7. 结论

第一，在 34,115 个初始缺失名称的 restId 中，基于评论候选投票、规则清洗及大语言模型辅助筛选，补全了 1,267 个有明确文本证据的商家名称；其余未填补记录并不代表商家不存在，而是评论中缺少足以可靠识别店名的证据。第二，先利用评论中的消费内容、菜品、服务和场景信息进行关键词规则分类，再对规则仍无法可靠判断的商家实施大语言模型复核；共接受 12,628 家商家的高置信度模型分类结果。最终为全体 243,247 家商家生成描述类别，其中“不确定”记录为 8,534 家。最终文件包含 restId、name 和描述类别三列，可作为后续商家业态统计和推荐系统特征构建的基础数据。